

Lab4. 非线性最小二乘

林昭炜 3170105728 数媒1701

1. 试验内容

本次实验分为如下任务和我完成的情况简介

实现 Gauss-Newton 迭代优化

在实验中我严格按照输入格式实现了我的 Gauss-Newton 迭代优化器 `class Solver5728` .

实现 Backtracking & Exact Line Search

实现了最简单的 Exact Line Search, 并且略做优化, 实现了 Backtracking Line Search.

实现 3 个 Residual Functions

三个 Functions 包括了:

- 线性函数的 Residual Function

```
1 LineResidual(double k, double b, int num_dots,  
2             bool perturb_x = false, bool perturb_y = false)
```

- 圆方程的 Residual Function

```
1 CircleResidual(double A, double B, double R)
```

- 椭圆方程的 Residual Function, 支持从文件里读入, 从而可以读入老师的测试样例

```
1 EclipseResidual(double A, double B, double C);  
2 EclipseResidual(std::string filename)
```

实现对实验结果可视化分析的 Python 脚本

很多时候我们很难判断输出结果正确与否, 或者结果拟合的情况, 所以我写了一个 Python 脚本从 C++ 输出的文件 (包含坐标和方程参数), 可视化结果, 方便判断与分析。

2. 实现环境

编译环境: Visual Studio 2019, C++ latest

运行环境: Windows 10, 16GB RAM, i7 7700HQ

OpenCV: 4.1.1

Python: 3.7 (matplotlib, numpy)

3. 理论基础

Gauss-Newton 迭代优化

高斯牛顿迭代法源于牛顿法，最速梯度下降法使用的是梯度作为每次迭代方向，而牛顿法考虑到了二阶导数的信息。但是在利用二阶信息的时候我们需要计算 Hessian 矩阵，而这个矩阵的计算消耗量比较大，空间也需要特别大，因此提出了专门针对最小二乘的 GN 算法。

首先我们知道最小二乘的公式如下: $F(\mathbf{x}) = \|R(\mathbf{x})\|_2^2$, 其中 $R(\mathbf{x})$ 是残差函数，我们对 $R(\mathbf{x})$ 进行泰勒展开代入原方程。首先我们计算一下:

$$J_F = \frac{\partial F}{\partial R} \cdot \frac{\partial R}{\partial x} = \frac{\partial(\|R\|_2^2)}{\partial R} \cdot J_R = 2R^T J_R \quad (1)$$

$$\begin{aligned} F(x + \Delta x) &= \|R(x + \Delta x)\|_2^2 \approx \|R(x) + J_R \Delta x\|_2^2 \\ &= \|R(x)\|_2^2 + 2R^T J_R \Delta x + \Delta x^T J_R^T J_R \Delta x \end{aligned}$$

By (1) we have:

$$= F(x) + J_F \Delta x + \Delta x^T J_R^T J_R \Delta x$$

我们想要最快到达目的，则意味着:

$$\begin{aligned} \frac{\partial F}{\partial \Delta x} &= \frac{\partial(F(x) + J_F \Delta x + \Delta x^T J_R^T J_R \Delta x)}{\partial \Delta x} \\ &= J_R^T J_R \Delta x + J_R^T R = 0 \end{aligned}$$

所以我们迭代的方向就是:

$$\Delta x = (J_R^T J_R)^{-1} J_R^T R \quad (2)$$

Backtracking Line Search

Exact Line Search 通过每一步迭代是匀速的，每隔一个间隔采样是否到达了目标。

Backtracking 方法更加聪明，对于 $F(x + \alpha \Delta x)$ 来说，我们确定了 $x, \Delta x$ ，而 α 是变量，我们不妨设为 $\phi(\alpha)$ ，那么我们希望能满足如下不等式:

$$\phi(\alpha) \leq \phi(0) + \gamma \phi'(\alpha) \alpha. \quad (3)$$

其中我们需要求出 $\phi'(0)$:

$$\begin{aligned} \phi'(0) &= \frac{dF(x + \alpha \Delta x)}{d\alpha} = \frac{dF(x + \alpha \Delta x)}{d(x + \alpha \Delta x)} \Delta x \\ &= \Delta F^T(x) \Delta x \\ &\approx \|\Delta x\|^2 \end{aligned}$$

Residual Functions

这里我们考察三种 Residual Functions。

对于直线我们有:

$$f(x) = kx + b$$

$$J_f[i] = [\frac{\partial f}{\partial k}, \frac{\partial f}{\partial b}] = [x_i, 1].$$

其中 $J_f[i]$ 是第 i 行 Jacobi 矩阵。

对于圆来说，我们使用参数方程生成：

$$f(\theta) = \begin{bmatrix} a + r * \cos(\theta) \\ b + r * \sin(\theta) \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \end{bmatrix}$$

其中 ϵ_1, ϵ_2 是随机的误差。

对应的求导有：

$$\nabla f(a, b, r) = \begin{bmatrix} -2 * (x - a) \\ -2 * (y - b) \\ -2 * r \end{bmatrix}$$

对于椭圆方程我们有生成的参数方程：

$$f(\theta, \varphi) = \begin{bmatrix} A \sin(\theta) \cos(\varphi) \\ B \sin(\theta) \sin(\varphi) \\ C \cos(\theta) \end{bmatrix} + \begin{bmatrix} \epsilon_1 \\ \epsilon_2 \\ \epsilon_3 \end{bmatrix}$$

同样的我们有对应的梯度：

$$\nabla f(A, B, C) = \begin{bmatrix} -2x^2/A^3 \\ -2y^2/B^3 \\ -2z^2/C^3 \end{bmatrix}$$

残差则是：

$$R(x, y, z, A, B, C) = \frac{x^2}{A^2} + \frac{y^2}{B^2} + \frac{z^2}{C^2} - 1$$

4. 实验细节

Gauss-Newton 迭代优化

Gauss-Newton 的核心算法如下，只要按照公式给出的写，用 OpenCV 的矩阵操作即可。

```
1 double solve(
2     ResidualFunction* pf,
3     double* pX,
4     GaussNewtonParams param = GaussNewtonParams(),
5     GaussNewtonReport* report = nullptr
6 ) override
7 {
```


Exact Line Search

大致思路是循环十次，每次如果残差下降的话我们就知道我们可以继续扩大我们的 Step, 但是如果 残差没有下降，我们需要减小 Step, 因此我们后退回原来的位置，把步长的变化率缩减为原来的十分之一。

设置了最大的迭代次数是 1000次，防止无限循环。

```
1  static double linear_search_algo(ResidualFunction& f, cv::Mat1d& R, cv::Mat1d& J, const
   cv::Mat1d& X, const cv::Mat& Dx, double min)
2  {
3      cv::Mat1d mX = X.clone();
4      double min_alpha = 0;
5      int i = 1; // step
6      double denominator = 1; // step size
7      double alpha = 0; // result
8      int n = 0; // iteration counter
9      bool reached = false; // if reach a place smaller than original
10
11     // If we completed 10 iterations, and at least one iteration
12     // found a suitable step size alpha
13     // Otherwise we will keep iterate for 1000 times waiting for the
14     // step that can minimize Residual
15     while (n < 10 || (!reached && n < 1000))
16     {
17         // step forward, compute new residual
18         alpha += i / denominator;
19         mX = X + alpha * Dx;
20         f.eval(data(R), data(J), data(mX));
21
22         // if the next step makes residual lesser , that is good
23         // we record the alpha(step size) as min_alpha
24         if (double eps = maxabs(R); eps < min)
25         {
26             min = eps;
27             min_alpha = alpha;
28             reached = true;
29         }
30         // The residual is larger than min, that means
31         // we may overstepped, therefore we withdraw the
32         // step, shrink our step size by factor of 10
33         else
34         {
35             alpha -= i / denominator;
36             denominator *= 10;
37             i = 0;
38         }
39         ++n;
40         ++i;
41     }
42     return min_alpha;
43 }
```

Backtracking Line Search

根据公式我们的伪代码如下：

```

1 double gamma, beta, alpha; // parameters
2 double phi = dot(dx, dx)
3 while F(x+alpha*dx) < F(x) + alpha * phi * gamma
4     alpha *= beta

```

然后我们检查小于的时候使用如下函数:

```

1 // check all elements in R is larger or equal to L
2 auto one_greater = [](const double* L, const double* R, int count)
3 {
4     for (int i = 0; i < count; ++i, ++L, ++R)
5         if (*L > *R)
6             return true;
7     return false;
8 };

```

Residual Functions

Residual Functions 我们可以根据在前一章提到的公式来写, 类和构造函数的签名如下:

```

1 class LineResidual : public ResidualFunction{
2     // ...
3     LineResidual(double k, double b, int num_dots,
4                  bool perturb_x = false, bool perturb_y = false); // will we add noise
5     // ...
6 }
7
8 class CircleResidual : public ResidualFunction
9 {
10     // ...
11     // (x-A)^2+(y-B)^2=R^2
12     CircleResidual(double A, double B, double R);
13     // ...
14 }
15
16 class EclipseResidual : public ResidualFunction
17 {
18     // ...
19     EclipseResidual(double A, double B, double C);
20     EclipseResidual(std::string filename);
21 }

```

而噪音的生成如下:

```

1 double noise(scale){
2     return (rand() % 256 - 256)/512.0 * scale;
3 }

```

Python Plotting

最后是 Python 绘制, 它从文件里读入两类数据: 优化后的参数和数据点, 然后用参数绘制拟合后的函数图像, 用数据点绘制散点图。

5. 结果展示与分析

结果展示

在程序里依次测试了直线、圆形和椭球的拟合, 其中椭球是从文件中读入, 实验指导书给的测试样例:

首先是使用 Backtracking:

```
iter    cost          cost_change    gradient      step    iter_time    total_time
0       1.07e+03        0.00e+00      4.10e+00      1.00e+00  3.49e+00     3.49e+00
truth: k 2.100000, b -3.100000
solved: k 2.099998, b -3.096921

iter    cost          cost_change    gradient      step    iter_time    total_time
0       2.25e+02        0.00e+00      6.63e+01      1.00e+00  1.88e-01     1.88e-01
1       4.25e+03        4.03e+03      3.26e+01      1.00e+00  6.14e-01     8.02e-01
2       1.06e+03       -3.19e+03      1.62e+01      1.00e+00  6.00e-01     1.40e+00
3       2.65e+02       -7.98e+02      7.97e+00      1.00e+00  7.07e-01     2.11e+00
4       6.53e+01       -1.99e+02      3.73e+00      1.00e+00  7.25e-01     2.83e+00
5       1.57e+01       -4.97e+01      1.45e+00      1.00e+00  7.77e-01     3.61e+00
6       3.89e+00       -1.18e+01      3.15e-01      1.00e+00  2.32e+00     5.94e+00
7       1.94e+00       -1.95e+00      1.64e-02      1.00e+00  9.40e-01     6.88e+00
8       2.04e+00        9.90e-02      4.47e-05      1.00e+00  7.25e-01     7.60e+00
circle truth: A 8.000000, B 9.000000, R 3.000000
circle solved: A 8.007536, B 9.003249, R -3.009540

iter    cost          cost_change    gradient      step    iter_time    total_time
0       1.53e+01        0.00e+00      5.50e-01      1.00e+00  5.61e-01     5.61e-01
1       6.67e+00       -8.65e+00      5.38e-01      1.00e+00  1.26e+00     1.82e+00
2       2.96e+00       -3.70e+00      3.84e-01      1.00e+00  1.12e+00     2.94e+00
3       1.41e+00       -1.55e+00      2.77e-01      1.00e+00  8.49e-01     3.79e+00
4       8.26e-01       -5.82e-01      1.11e-01      1.00e+00  8.65e-01     4.65e+00
5       6.72e-01       -1.54e-01      1.24e-02      1.00e+00  8.59e-01     5.51e+00
6       6.57e-01       -1.52e-02      1.30e-04      1.00e+00  8.60e-01     6.37e+00
truth: A nan, B nan, C nan
solved: A 2.944047, B 2.305035, C 1.797825
```

然后是使用 Exact Line Search:

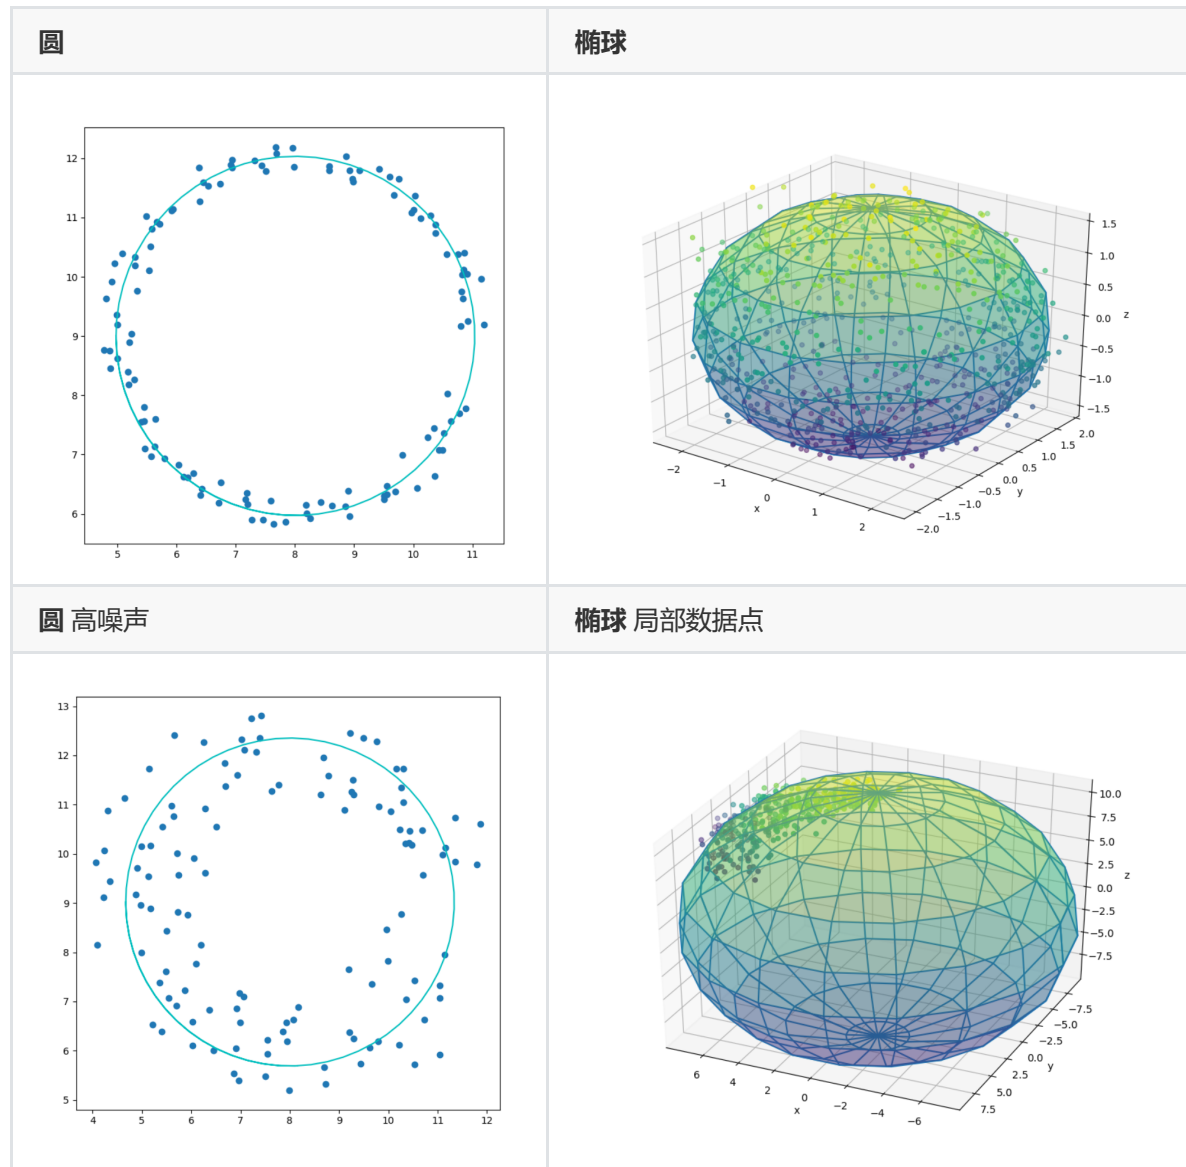
```
iter    cost          cost_change    gradient      step    iter_time    total_time
0       1.07e+03        0.00e+00      4.10e+00      1.00e+00  3.72e+00     3.72e+00
truth: k 2.100000, b -3.100000
solved: k 2.099998, b -3.096921

iter    cost          cost_change    gradient      step    iter_time    total_time
0       2.25e+02        0.00e+00      6.63e+01      1.66e-01  6.31e-01     6.31e-01
1       7.08e+01       -1.54e+02      9.47e+00      1.00e+00  9.16e-01     1.55e+00
2       1.08e+01       -6.00e+00      8.34e+00      3.00e-01  7.57e-01     2.30e+00
3       1.91e+00       -8.91e+00      2.22e-02      3.60e-02  8.05e-01     3.11e+00
Search stopped at local minimum
circle truth: A 8.000000, B 9.000000, R 3.000000
circle solved: A 8.007536, B 9.003249, R -3.031022

iter    cost          cost_change    gradient      step    iter_time    total_time
0       1.53e+01        0.00e+00      5.50e-01      6.00e+00  3.15e+00     3.15e+00
1       7.24e-01       -1.46e+01      3.82e+00      4.50e-01  3.59e+00     6.74e+00
Search stopped at local minimum
truth: A nan, B nan, C nan
solved: A 3.035086, B 2.534716, C 1.856544
```

可以发现 Exact Line Search 每次迭代速度比较慢, 但需要迭代的次数比较小, 相反, Backtracking 每次迭代非常快, 但是需要更多次迭代, 除此之外 Backtracking 在拟合 Circle 上更加接近 Truth。

Python 可视化如下:



在局部数据点的情况下，如果初值给得太大，会导致优化时收敛到一个非常大的参数上。

6. 编译运行

编译说明

本次实验需要支持 C++17 的编译器。

需要用到 OpenCV. 请把 `bin/OpenCV411.dll` 拷贝到 `src/OpenCVHW1/` 目录下

对于 Python 来说, 需要 `matplotlib` 和 `numpy` 这两个包。

运行说明

提供了测试时编译的好的 Release 文件，在命令行内可以运行。

Python 文件也可以直接运行。